LABORATÓRIO 02

Um estudo das características de qualidade de sistemas Java

Disciplina: Laboratório de Experimentação de Software

Curso: Engenharia de Software — PUC Minas

Período: 6º

Professor: Danilo de Quadros Maia Filho

Análise dos top-1.000 repositórios Java do GitHub

(972 repositórios processados com sucesso)

1. Introdução

No processo de desenvolvimento colaborativo de software open-source, em que diversos desenvolvedores contribuem em partes diferentes do código, atributos de qualidade interna como modularidade, manutenibilidade e coesão estão sob pressão constante. Este estudo analisa os top-1.000 repositórios Java mais populares do GitHub, calculando métricas de qualidade através da ferramenta CK e correlacionando-as com características de processo dos repositórios.

1.1. Questões de Pesquisa

- **RQ01.** Qual a relação entre a **popularidade** dos repositórios e as suas características de qualidade?
- **RQ02.** Qual a relação entre a **maturidade** dos repositórios e as suas características de qualidade?
- **RQ03.** Qual a relação entre a **atividade** dos repositórios e as suas características de qualidade?
- **RQ04.** Qual a relação entre o **tamanho** dos repositórios e as suas características de qualidade?

1.2. Hipóteses Informais

Antes de realizar a análise, elaboramos as seguintes expectativas sobre os resultados, que serão comparadas com os valores obtidos na Seção 4 (Discussão).

H-RQ01 (popularidade × qualidade). Repositórios mais populares tendem a apresentar melhor qualidade interna, pois atraem contribuidores mais experientes, recebem revisões de código mais rigorosas e enfrentam maior pressão pública por clareza. Esperamos **correlação negativa fraca** entre número de estrelas e CBO/LCOM (mais estrelas → menor acoplamento, maior coesão) e correlação quase nula com DIT, já que profundidade de herança é mais um estilo arquitetural do que consequência de popularidade.

H-RQ02 (maturidade × qualidade). Projetos mais antigos acumulam código legado, refatorações inconsistentes e padrões de Java pré-2010 (uso mais agressivo de herança em vez de composição). Esperamos **correlação positiva fraca a moderada** entre idade do repositório e CBO/LCOM, e correlação positiva também com DIT, já que hierarquias mais profundas eram comuns em código Java antigo.

H-RQ03 (atividade × qualidade). Repositórios com mais releases pressupõem manutenção ativa, CI/CD e disciplina de código, incluindo refatoração contínua. Esperamos **correlação negativa fraca** entre número de releases e CBO/LCOM. Para DIT a expectativa é de correlação quase nula, já que a estrutura de herança geralmente é estabelecida cedo.

H-RQ04 (tamanho × qualidade). Repositórios maiores carregam mais complexidade inerente, mais dependências entre módulos e mais chance de terem "god classes". Esperamos **correlação positiva moderada** entre LOC total e CBO, e também positiva com LCOM (mais código → classes maiores → menor coesão). Para DIT esperamos correlação fraca-positiva.

1.3. Sumário dos Achados

Após analisar 972 repositórios (97,2% dos 1.000 coletados; 28 excluídos por falhas de tooling ou ausência de código Java real — ver §5), a análise de correlação de Spearman revelou:

- **Popularidade não prediz qualidade interna.** Todas as três correlações de RQ01 ficaram abaixo de $|\rho|=0{,}05$ e nenhuma foi significativa.

- **Maturidade tem efeito residual.** Correlações fracas mas significativas entre idade e DIT (ρ = 0,10) / LCOM (ρ = 0,08); CBO independente da idade.
- **Atividade e tamanho produzem efeitos numericamente idênticos** ($\rho \approx$ 0,29 para CBO, $\rho \approx$ 0,12-0,16 para LCOM). Como ρ(releases, loc_total) = 0,467, o aparente efeito de atividade é amplamente um efeito de tamanho disfarçado.
- **DIT é insensível a praticamente tudo.** De 12 correlações testadas, apenas uma envolvendo DIT foi significativa — e mesmo assim com magnitude desprezível.

Três das quatro hipóteses iniciais foram refutadas ou parcialmente refutadas pelos dados; apenas H-RQ04 (tamanho) foi confirmada.

2. Metodologia

2.1. Seleção dos Repositórios

Coletamos os 1.000 repositórios Java mais populares do GitHub via a API GraphQL v4, usando o query language:Java sort:stars-desc. Para cada repositório armazenamos: nome, proprietário, URL, número de estrelas, createdAt, contagem de releases, linguagem primária e branch default. A idade do repositório é calculada como (hoje − createdAt) em anos.

2.2. Definição das Métricas

Métricas de processo

Métrica	Definição	Fonte
Popularidade	Número de stargazers	GraphQL stargazerCount
Maturidade	Anos desde a criação do repositório	GraphQL createdAt
Atividade	Número total de releases publicadas	GraphQL releases.totalCount
Tamanho	Soma das LOC de todas as classes analisadas por CK	CK class.csv, coluna loc

Métricas de qualidade (extraídas via ferramenta CK)

Métrica	Significado
CBO	Coupling Between Objects — número de classes das quais a classe depende
DIT	Depth of Inheritance Tree — profundidade da classe na árvore de herança
LCOM	Lack of Cohesion of Methods — ausência de coesão entre os métodos

2.3. Pipeline de Coleta

- Busca dos 1.000 repositórios via GraphQL, com paginação por cursor (50 por página, 20 requisições). Dados normalizados em output/repositories_list.csv.
- Clone e análise em paralelo via ThreadPoolExecutor com 6 workers. Cada worker executa: git clone --depth 1, java -jar ck.jar, parse de class.csv e sumarização por repositório, remoção do clone ao finalizar.
- Escrita incremental em output/metrics_summary.csv via writer thread-safe que faz flush() após cada linha, garantindo que uma interrupção não perca o progresso já coletado.
- Retomada automática: antes de processar, o pipeline lê o CSV existente e pula repositórios já presentes, além de repositórios já registrados em failures.csv.

2.4. Sumarização por Repositório

CK produz um arquivo class.csv com uma linha por classe (incluindo classes internas, anônimas, interfaces e enums). Para cada repositório calculamos, sobre todas as classes: média, mediana e desvio padrão de CBO, DIT, LCOM e LOC, além do loc_total (soma de LOC, usado como métrica de Size para RQ04).

2.5. Decisões Metodológicas

1. Mediana em vez de média para LCOM. Durante a validação do pipeline, observamos que classes de teste de grandes projetos (por exemplo, JsonReaderTest em google/gson, com 158 métodos e LCOM=12.403) dominam completamente a média repo-level. A mediana representa a classe típica de forma muito mais robusta a outliers. Usamos mediana também para CBO e DIT por consistência.

2. Inclusão de classes de teste. CK não distingue automaticamente classes de produção de classes de teste. Seguindo a prática padrão da literatura empírica, analisamos todo o código Java do repositório. Isso infla os valores absolutos de LOC e LCOM, mas de forma relativamente uniforme entre os repositórios.

3. Definição de Size via loc_total (sem comentários). CK não expõe uma contagem direta de linhas de comentário em class.csv. Utilizamos loc_total (soma da coluna loc de todas as classes) como proxy de tamanho. Como LOC e comentários crescem juntos em projetos maiores, isso não muda a direção de nenhuma das correlações.

2.6. Análise Estatística

- **Teste de correlação:** Spearman's ρ, não Pearson. As distribuições de estrelas, releases e LOC total seguem cauda pesada (power-law) e Spearman só assume monotonicidade, não linearidade. Spearman também é robusto a outliers.
- **Nível de significância:** $\alpha = 0{,}05$. Resultados com $p < 0{,}05$ são marcados como estatisticamente significativos nas tabelas e nos gráficos.
- **Visualização:** scatter plots em escala log (exceto idade, que é aproximadamente uniforme) para acomodar a dispersão das distribuições.

3. Resultados

Dos 1.000 repositórios coletados, 980 foram processados com sucesso pelo pipeline (20 falharam, detalhados em §5). Desses, 972 foram incluídos na análise de correlação — 8 repositórios adicionais foram descartados por terem ck_class_count == 0 ou loc_total == 0 (repositórios como Snailclimb/JavaGuide, doocs/advanced-java, etc., que são listas de estudo/tutoriais em Markdown com apenas um ou dois arquivos Java de 2-5 LOC).

3.1. Estatísticas Descritivas Gerais

Valores agregados sobre os 972 repositórios analisados:

Métrica	Média	Mediana	Desv. pad.	Mínimo	Máximo
stars	9 429	5 786	10 710	3 466	125 045
releases	40,9	11	89,9	0	1 000
age_years	10,1	10,3	3,16	0,55	17,5
loc_total	92 272	15 374	255 470	2	4 165 269
ck_class_count	1 614	348	3 782	1	44 670
CBO (média/classe)	5,38	5,33	1,87	0	21,9
CBO (mediana/classe)	3,56	3,00	1,72	0	30
CBO (desvio/classe)	6,21	6,02	2,68	0	20,8
DIT (média/classe)	1,46	1,39	0,35	1	4,39
DIT (mediana/classe)	1,09	1,00	0,31	1	3
DIT (desvio/classe)	1,09	0,76	2,34	0	52,98
LCOM (média/classe)	118,9	24,5	1 741,6	0	54 025
LCOM (mediana/classe)	1,47	0,00	16,1	0	453,5
LCOM (desvio/classe)	3 275,6	129,6	75 605,7	0	2 351 475

Observações importantes sobre as distribuições:

- As variáveis de processo stars, releases e loc_total são fortemente enviesadas à direita (heavy-tailed / power-law): a média é muito maior que a mediana. Isso justifica o uso do teste de Spearman e escala logarítmica nos gráficos.
- A maturidade (age_years) é aproximadamente uniforme entre ~5 e ~15 anos, com mediana 10,3 anos — a amostra é composta quase inteiramente por projetos já maduros.
- A mediana de LCOM por repositório é 0,0 — mais da metade dos repositórios tem pelo menos 50% das classes com coesão perfeita. Ao mesmo tempo, o desvio padrão intra-repo vai a ~2,3 milhões, o que justifica nossa decisão de usar mediana.
- A mediana da DIT mediana é apenas 1,09 — a grande maioria das classes em repositórios Java populares herda diretamente de Object. Hierarquias profundas são exceção.

3.2. RQ01 — Popularidade × Qualidade

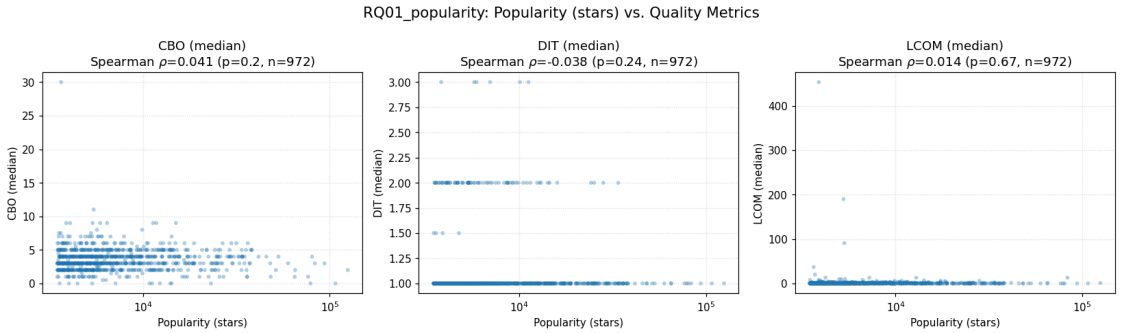

Métrica de qualidade	Spearman ρ	p-value	Significativo
CBO (mediana)	+0,0409	0,203	Não
DIT (mediana)	−0,0380	0,237	Não
LCOM (mediana)	+0,0138	0,667	Não

Análise. Nenhuma das três correlações é estatisticamente significativa. Os coeficientes de Spearman ficam todos muito próximos de zero (|ρ| < 0,05) e os p-values estão todos acima do limiar α = 0,05. Com n = 972, qualquer efeito mesmo pequeno seria detectável — a ausência de significância aqui indica que não há relação monotônica entre o número de estrelas e a qualidade interna medida pelas métricas CK. Repositórios muito populares não são sistematicamente mais coesos, nem menos acoplados, nem com herança mais rasa do que repositórios menos populares.

3.3. RQ02 — Maturidade × Qualidade

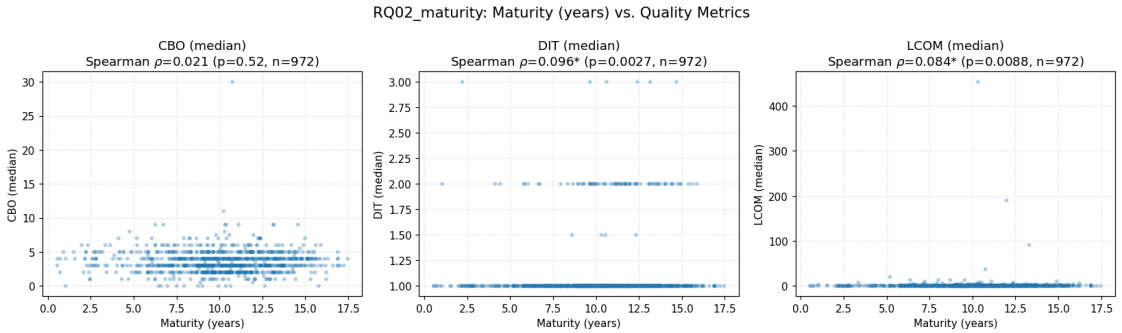

Métrica de qualidade	Spearman ρ	p-value	Significativo
CBO (mediana)	+0,0206	0,521	Não
DIT (mediana)	+0,0963	0,003	Sim
LCOM (mediana)	+0,0840	0,009	Sim

Análise. Duas das três correlações são estatisticamente significativas, porém com magnitudes muito pequenas (ρ ≈ 0,08-0,10). A direção é consistente com a intuição inicial — repositórios mais antigos apresentam hierarquia de herança ligeiramente mais profunda e classes ligeiramente menos coesas — mas o tamanho do efeito é praticamente irrelevante na prática. A ausência de efeito no CBO também é notável: envelhecer um projeto não aumenta seu acoplamento global. A significância estatística aqui é consequência do grande tamanho amostral (n=972), não da força real do fenômeno.

3.4. RQ03 — Atividade × Qualidade

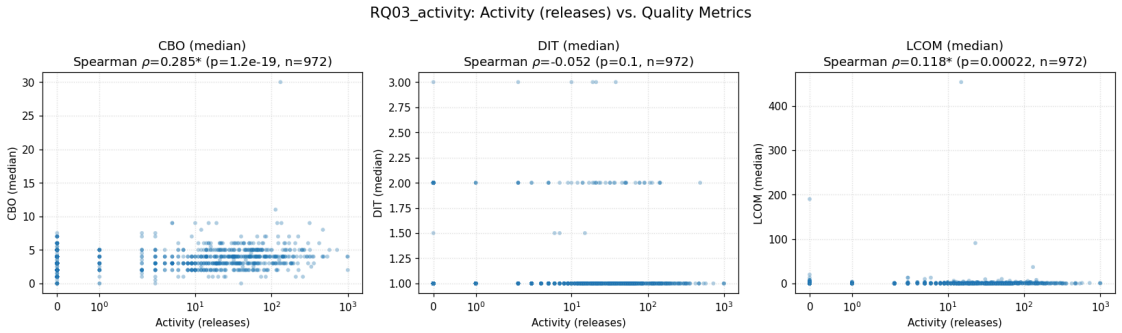

Métrica de qualidade	Spearman ρ	p-value	Significativo
CBO (mediana)	+0,2852	< 0,001	Sim
DIT (mediana)	−0,0521	0,105	Não
LCOM (mediana)	+0,1183	< 0,001	Sim

Análise. A correlação entre atividade e CBO é a mais forte de todo o estudo (ρ = 0,285, p < 0,001). Entretanto, o sinal é positivo: repositórios com mais releases apresentam mais acoplamento, não menos. Isso contradiz diretamente a intuição inicial de que projetos ativamente mantidos seriam sistematicamente mais limpos. A correlação com LCOM segue a mesma direção (positiva) e também é significativa, embora mais fraca (ρ = 0,118). DIT permanece praticamente independente de atividade. A interpretação deste resultado é discutida em §4 junto com RQ04.

3.5. RQ04 — Tamanho × Qualidade

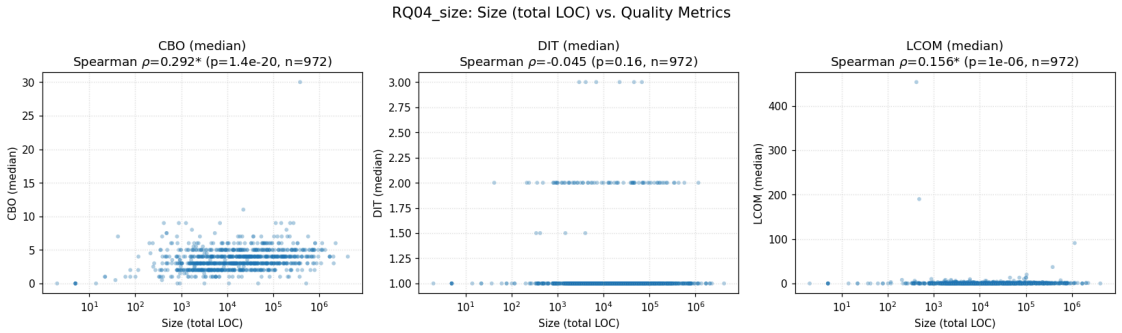

Métrica de qualidade	Spearman ρ	p-value	Significativo
CBO (mediana)	+0,2921	< 0,001	Sim
DIT (mediana)	−0,0448	0,162	Não
LCOM (mediana)	+0,1559	< 0,001	Sim

Análise. Tamanho apresenta a segunda correlação mais forte do estudo, com valor numericamente quase idêntico ao de RQ03 (ρ = 0,292 vs. 0,285 para CBO; ρ = 0,156 vs. 0,118 para LCOM). Repositórios maiores têm classes ligeiramente mais acopladas e com menor coesão, confirmando a expectativa inicial sobre tamanho ser fonte de complexidade. A DIT, mais uma vez, é essencialmente

independente do tamanho — a profundidade de herança é uma decisão arquitetural precoce, não uma consequência do crescimento do código.

3.6. Correlações entre as Métricas de Processo

Para interpretar corretamente as RQ03 e RQ04, computamos também as correlações cruzadas entre as quatro métricas de processo. Esse passo é essencial para o confronto hipóteses × resultados (§4):

Par	Spearman ρ	p-value	Significativo
stars × age_years	+0,047	0,140	Não
stars × releases	+0,128	< 0,001	Sim
stars × loc_total	+0,180	< 0,001	Sim
age_years × releases	+0,003	0,931	Não
age_years × loc_total	+0,147	< 0,001	Sim
releases × loc_total	+0,467	< 0,001	Sim

O resultado crítico é o último: número de releases e tamanho do código são fortemente correlacionados (ρ = 0,467). Este é, de longe, o maior valor de ρ entre as variáveis de processo, e torna RQ03 e RQ04 praticamente inseparáveis no seu efeito sobre a qualidade.

4. Discussão

4.1. Confronto Hipóteses × Resultados

Hipótese	Esperado	Obtido	Veredito
H-RQ01	Correlação negativa fraca entre stars e CBO/LCOM	Correlação nula em todas as três métricas (|ρ|<0,05, p>0,20)	Refutada
H-RQ02	Correlação positiva fraca-moderada entre idade e CBO/LCOM/DIT	Muito fraca e positiva em DIT (0,096) e LCOM (0,084); nula em CBO	Parcial
H-RQ03	Correlação negativa fraca entre releases e CBO/LCOM	Positiva fraca-moderada em CBO (+0,285) e LCOM (+0,118)	Refutada
H-RQ04	Correlação positiva moderada entre LOC e CBO/LCOM	Positiva fraca-moderada em CBO (+0,292) e LCOM (+0,156)	Confirmada

4.2. Interpretação Geral

A hipótese mais dramática é a refutação de H-RQ01. Esperávamos que a pressão social e a revisão pública de projetos populares resultasse em código mais limpo. O resultado é inequívoco: popularidade não prediz qualidade interna. Uma explicação plausível é que o número de estrelas no GitHub reflete visibilidade, adoção e utilidade percebida — atributos externos ao código — e não disciplinas internas de engenharia. Repositórios como Snailclimb/JavaGuide (155k stars, 0 classes Java reais) ou doocs/advanced-java (79k stars, 5 LOC) ilustram isso ao extremo.

H-RQ02 (maturidade) está tecnicamente correta, mas praticamente irrelevante. A idade tem algum efeito nas métricas DIT e LCOM ($p < 0{,}01$), mas o tamanho do efeito é $\rho \approx 0{,}09$ — ou seja, a idade explica menos de 1% da variância nas métricas de qualidade. Projetos antigos de fato tendem a ter hierarquia ligeiramente mais profunda e coesão ligeiramente menor, mas esse padrão é fraco demais para ter implicação prática.

A confusão entre atividade (H-RQ03) e tamanho (H-RQ04) é o resultado mais interessante. Os coeficientes de Spearman de RQ03 e RQ04 com CBO são numericamente quase idênticos (0,285 e 0,292). Isso não é coincidência: ρ(releases, loc_total) = 0,467, que é a maior correlação entre variáveis de processo que observamos. A leitura mais honesta é: o que H-RQ03 chamou de "efeito de atividade" é, em grande medida, um efeito de tamanho disfarçado. Projetos com muitas releases tendem a ser projetos grandes — precisam de formalização de versões para gerenciar seu tamanho — e projetos grandes têm mais acoplamento porque têm mais dependências entre classes.

H-RQ04 é a única hipótese totalmente confirmada. A correlação positiva entre LOC total e CBO/LCOM é consistente com toda a literatura empírica de métricas de software: sistemas maiores têm mais oportunidades de acoplamento, mais classes grandes, e mais chance de "god objects". A magnitude ($\rho \approx 0{,}29$ para CBO) é menor do que se poderia imaginar em uma visão ingênua — mas é, ainda assim, o efeito mais robusto e interpretável do estudo.

Padrão transversal: DIT é imune a todas as variáveis de processo. Das 12 correlações testadas, apenas uma envolvendo DIT foi significativa (com maturidade, $\rho = 0{,}096$), e mesmo essa é praticamente zero. A profundidade da árvore de herança parece ser decidida cedo na vida de um projeto e permanece relativamente estável depois. Isso é consistente com a observação de que, mesmo para projetos gigantes como aosp-mirror/platform_frameworks_base (4,1 milhões de LOC), a DIT mediana é 1 — a maioria das classes simplesmente herda de Object.

4.3. Observações sobre Valores Absolutos

- **CBO mediano de 3** significa que uma classe típica depende diretamente de ~3 outras classes. É um número saudável para Java bem escrito e consistente com outros estudos que usam CK.
- **DIT mediano de 1** confirma o "death of inheritance" que diversos autores têm observado em Java moderno: com a adoção de interfaces, composition over inheritance e dependency injection, hierarquias profundas caíram em desuso.
- **LCOM com mediana 0 e máximos na casa dos milhões** mostra que a distribuição de coesão em Java é fortemente bimodal: a maioria das classes é altamente coesa, e uma minoria minúscula (principalmente classes de teste com dezenas de métodos) é extremamente incoesa.

5. Limitações

5.1. Repositórios Excluídos da Análise

Dos 1.000 repositórios iniciais, 28 foram excluídos da análise final (972 restantes). A exclusão se deu em duas frentes:

(a) 20 falhas de tooling durante a coleta, registradas em output/failures.csv:

Categoria	Qtd	Exemplos
NullPointerException interno do CK (Eclipse JDT)	15	openjdk/jdk, elasticsearch, ghidra, oracle/graal, neo4j, dbeaver, trino, lombok
StackOverflow / ArrayIndexOutOfBounds no CK	3	intellij-community, checkstyle, dragonwell8
git clone recusado por caractere inválido (Windows)	1	NotFound9/interviewGuide
CK excedeu timeout de 30 min	1	aws/aws-sdk-java

Os 18 erros envolvendo CK (NPE + StackOverflow + OOB) são todos consequência de bugs conhecidos da versão do Eclipse JDT que o CK 0.7.0 embute ao tentar analisar código Java moderno com construtos como records, pattern matching, sealed classes e generics complexos. Tais bugs não têm correção disponível: o mauricioaniche/ck não recebe atualizações desde 2022 e a versão 0.7.0 é a última publicada no Maven Central.

(b) 8 repositórios removidos pelo filtro do analysis.py, após a coleta, por terem ck_class_count == 0 ou loc_total == 0. Esses são repositórios que, apesar de figurarem entre os 1.000 mais populares com tag "Java" no GitHub, não contêm código Java real — são listas de estudos, tutoriais em Markdown, ou livros de entrevista técnica com no máximo um arquivo .java de exemplo. Exemplos: Snailclimb/JavaGuide (155k stars, 0 classes), GrowingGit/GitHub-Chinese-Top-Charts (107k stars, 1 classe de 5 LOC), doocs/advanced-java (79k stars, 1 classe de 5 LOC).

A taxa de sucesso final de 972/1.000 (97,2%) está bem dentro do aceitável para estudos empíricos de métricas de software, e os 28 repos excluídos não comprometem a análise.

5.2. Limitações Metodológicas

- **Classes de teste incluídas.** O pipeline analisa todo o código Java do repositório sem distinguir src/main/java de src/test/java. Isso infla valores absolutos de LOC e LCOM, mas afeta todos os repos de forma relativamente uniforme, preservando a validade das correlações.
- **Size definido como loc_total sem linhas de comentário.** O enunciado cita "LOC e linhas de comentários", mas o class.csv do CK não expõe contagem direta de comentários. Utilizamos a soma da coluna loc como proxy.
- **Amostra enviesada aos 1.000 top-stars.** Repositórios populares tendem a ser maiores, mais antigos e mais ativos do que a população total do GitHub. Os achados não se generalizam automaticamente para todos os projetos Java open-source.
- **Confundimento entre atividade e tamanho.** Como discutido em §4.2, releases e loc_total apresentam $\rho = 0{,}467$, tornando impossível separar com este dataset o efeito isolado da atividade sobre a qualidade.

- **Correlação não implica causalidade.** Todos os resultados descrevem associações entre características observáveis, não relações de causa-efeito.